

追加検証.2

他アーキテクチャによるトークナイザー効率可視化ならびに日本語ボトルネック検証

日本語

文章1

これは、文字の種類における、意味情報の圧縮効率を測るためのテスト用テキストです。
何を見るのかと言うと、文字数と、トークン数です。文字数はそのまま文字数をカウントし、トークン数は、OpenAIが出しているTokenizerを用いて測ります。
トークン数に関してはモデルによって差が出るかもしれませんが、とりあえずGPT5.xでのトークン数測定を一旦のデータとさせていただきます。
日本語に関してはテスト実行者が自ら文字を入力しているのですが、英語・中国語・韓国語に関してはAIによる翻訳です。翻訳は、楽天が出しているRakuten AI 3.0に任せます。
あくまで意味情報の圧縮率とトークン効率をなんとなく可視化するものなので、厳密さは求めないでください。
これで、テスト用文章の終わりとさせていただきます。

モデル名 (クリックで可視化)	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	355	216	1.644	60.85%
DeepSeek-V4-Pro	355	216	1.644	60.85%
LFM2.5-8B-A1B	355	190	1.868	53.52%
Llama-3-ELYZA-JP-8B	355	236	1.504	66.48%
Mistral-Medium-3.5-128B	355	248	1.431	69.86%
Qwen2.5-72B-Instruct	355	213	1.667	60.00%
Qwen3.6-27B	355	169	2.101	47.61%
RakutenAI-3.0	355	216	1.644	60.85%
diffusiongemma-26B-A4B-it	355	166	2.139	46.76%
gemma-4-31B-it	355	166	2.139	46.76%

文章2

えーマジさ、バナナってちょー美味くね？w
なんつーかさ、あのもさとした独特の食感がたまんねえわけ
あと、何日か置いて黒くなってきたときの甘さときたら、もうたまらんわな！
牛乳と一緒にいただくと、最高に美味いんだ！

モデル名（クリックで可視化）	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	107	83	1.289	77.57%
DeepSeek-V4-Pro	107	83	1.289	77.57%
LFM2.5-8B-A1B	107	71	1.507	66.36%
Llama-3-ELYZA-JP-8B	107	84	1.274	78.50%
Mistral-Medium-3.5-128B	107	89	1.202	83.18%
Qwen2.5-72B-Instruct	107	80	1.338	74.77%
Qwen3.6-27B	107	70	1.529	65.42%
RakutenAI-3.0	107	83	1.289	77.57%
diffusiongemma-26B-A4B-it	107	70	1.529	65.42%
gemma-4-31B-it	107	70	1.529	65.42%

文章3

我が邦における、東京湾上で発見された巨大不明生物、通称ゴジラについての処遇に関する閣議を始めます。

つきましては、ゴジラに対してどのようなアプローチを取るのか。

選択肢は、静観、駆除、捕獲のいずれかを選んで頂くようになります。

いかなる選択肢であろうとも、防衛省にて十分協議し、あらゆる作戦行動を実行可能といたします。

モデル名（クリックで可視化）	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	159	110	1.445	69.18%
DeepSeek-V4-Pro	159	110	1.445	69.18%
LFM2.5-8B-A1B	159	95	1.674	59.75%
Llama-3-ELYZA-JP-8B	159	118	1.347	74.21%
Mistral-Medium-3.5-128B	159	123	1.293	77.36%
Qwen2.5-72B-Instruct	159	110	1.445	69.18%
Qwen3.6-27B	159	86	1.849	54.09%
RakutenAI-3.0	159	110	1.445	69.18%
diffusiongemma-26B-A4B-it	159	93	1.710	58.49%
gemma-4-31B-it	159	93	1.710	58.49%

文章1(漢字なしバージョン)

これは、もじのしゅるいにおける、いみじょうほうのあっしゅくこうりつをはかるためのテストようテキストです。

なにをみるのかというと、もじすうと、トークンすうです。もじすうはそのままもじすうをカウントし、トークンすうは、OpenAIがだしているTokenizerをもちいてはかります。

トークンすうにかんしてはモデルによってさがでるかもしれませんが、とりあえずGPT5.xでのトークンすうそくていをいったんのデータとさせていただきます。

にほんごにかんしてはテストじっこうしゃがみずからもじをにゅうりよくしているのですが、えいご・ちゅうごくご・かんこくごにかんしてはAIによるほんやくです。ほんやくは、らくてんがだしているRakuten AI 3.0にまかせます。

あくまでいみじょうほうのあっしゅくりつとトークンこうりつをなんとなくかしかするものなので、げんみつさはもとめないでください。

これで、テストようぶんしょうのおわりとさせていただきます。

モデル名 (クリックで可視化)	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	423	289	1.464	68.32%
DeepSeek-V4-Pro	423	289	1.464	68.32%
LFM2.5-8B-A1B	423	264	1.602	62.41%
Llama-3-ELYZA-JP-8B	423	299	1.415	70.69%
Mistral-Medium-3.5-128B	423	288	1.469	68.09%
Qwen2.5-72B-Instruct	423	281	1.505	66.43%
Qwen3.6-27B	423	239	1.770	56.50%
RakutenAI-3.0	423	289	1.464	68.32%
diffusiongemma-26B-A4B-it	423	243	1.741	57.45%
gemma-4-31B-it	423	243	1.741	57.45%

文章1(ローマ字入力)

koreha,mojinosyuruiniokeru,imijouhounoassyukukourituwohakarutamenotesutoyoutekisut
odesu.

naniwomirunokatoiuto,mojisuuto,to-
kunsuudesu.mojisuuhasonomamamojisuuwokaunntosi,to-
kunnsuuha,OpenAIgadasiteiruTokenizerwomotiitehakarimasu.

to-kunnsuunikannsitehamoderuniyottesagaderukamosiremasennga,toriaezuGPT5.xdenoto-
kunnsuusokuteiwoittannnode-tatosaseteitadakimasu.

nihonngonikannsitehatesutojikkoshagamizukaramojiwonyuuryokusiteirunodesuga,eigo,ty
uugokugo,kannkokugonikannsitehaAIinioruhonnyakudesu.honnyakuha,rakutengadasiteiruR
akuten AI 3.0nimakasemasu.

akumadeimijouhounoassyukuritutoto-
kunnkourituwonanntonakukasikasuremononanode,gennmitusahamotomenaidekudasai.

korede,tesutoyoubunshounoowaritosaseteitadakimasu.

モデル名 (クリックで可視化)	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	713	295	2.417	41.37%
DeepSeek-V4-Pro	713	295	2.417	41.37%
LFM2.5-8B-A1B	713	307	2.322	43.06%
Llama-3-ELYZA-JP-8B	713	306	2.330	42.92%
Mistral-Medium-3.5-128B	713	290	2.459	40.67%
Qwen2.5-72B-Instruct	713	306	2.330	42.92%
Qwen3.6-27B	713	290	2.459	40.67%
RakutenAI-3.0	713	295	2.417	41.37%
diffusiongemma-26B-A4B-it	713	298	2.393	41.80%
gemma-4-31B-it	713	298	2.393	41.80%

文章1(漢字増やしバージョン)

これは、文字の種類に於ける、意味情報の圧縮効率を測る為のテスト用テキストです。
何を見るのかと言うと、文字数と、トークン数です。文字数は其の仮文字数をカウントし、トークン数は、OpenAIが出しているTokenizerを用いて測ります。
トークン数に関してはモデルによって差が出るかもしれませんが、とりあえずGPT5.xでのトークン数測定を一旦のデータとさせていただきます。
日本語に関してはテスト実行者が自ら文字を入力しているのですが、英語・中国語・韓国語に関してはAIによる翻訳です。翻訳は、楽天が出しているRakuten AI 3.0に任せます。
飽く迄で意味情報の圧縮率とトークン効率をなんとなく可視化する物なので、厳密さは求めないでください。
これで、テスト用文章の終わりとさせていただきます。

モデル名 (クリックで可視化)	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	347	223	1.556	64.27%
DeepSeek-V4-Pro	347	223	1.556	64.27%
LFM2.5-8B-A1B	347	203	1.709	58.50%
Llama-3-ELYZA-JP-8B	347	244	1.422	70.32%
Mistral-Medium-3.5-128B	347	256	1.355	73.78%
Qwen2.5-72B-Instruct	347	218	1.592	62.82%
Qwen3.6-27B	347	178	1.949	51.30%
RakutenAI-3.0	347	223	1.556	64.27%
diffusiongemma-26B-A4B-it	347	178	1.949	51.30%

モデル名（クリックで可視化）	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
gemma-4-31B-it	347	178	1.949	51.30%

文章1(エセ中国語風味)

此乃文字種類於意味情報圧縮効率測定之試験用文本。
所観者、文字数与令牌数。
文字数者即文字数計数、令牌数者以OpenAI公開Tokenizer測定。
令牌数關於模型差異或有出現、然姑且以GPT5.x於令牌数測定結果為暫定資料。
日本語關於試験実行者自入力、英語・中国語・韓国語關於AI翻訳。
翻訳委任於楽天所出Rakuten AI 3.0。
本文本飽迄為意味情報圧縮率与令牌効率之概略可視化用物、故勿求厳密。
以上、試験用文章終。

モデル名（クリックで可視化）	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	215	149	1.443	69.30%
DeepSeek-V4-Pro	215	149	1.443	69.30%
LFM2.5-8B-A1B	215	160	1.344	74.42%
Llama-3-ELYZA-JP-8B	215	176	1.222	81.86%
Mistral-Medium-3.5-128B	215	189	1.138	87.91%
Qwen2.5-72B-Instruct	215	173	1.243	80.47%
Qwen3.6-27B	215	150	1.433	69.77%
RakutenAI-3.0	215	149	1.443	69.30%
diffusiongemma-26B-A4B-it	215	149	1.443	69.30%
gemma-4-31B-it	215	149	1.443	69.30%

簡体中国語

文章1

这是一段用于测量不同文字种类中语义信息压缩效率的测试文本。
我们关注的是字符数和 token 数。字符数按原样计数，token 数使用 OpenAI 提供的 Tokenizer 进行测量。
关于 token 数，可能会因模型不同而有所差异，但暂且以 GPT5.x 的 token 计数作为临时数据。
日语部分由测试执行者本人输入，而英语、中文、韩语部分为 AI 翻译。翻译由乐天推出的 Rakuten AI 3.0 完成。
这只是为了大致可视化语义信息的压缩率与 token 效率，请不要过分追求严格的严谨性。
至此，测试用文本结束。

モデル名（クリックで可視化）	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	267	137	1.949	51.31%
DeepSeek-V4-Pro	267	137	1.949	51.31%
LFM2.5-8B-A1B	267	164	1.628	61.42%
Llama-3-ELYZA-JP-8B	267	173	1.543	64.79%
Mistral-Medium-3.5-128B	267	199	1.342	74.53%
Qwen2.5-72B-Instruct	267	150	1.78	56.18%
Qwen3.6-27B	267	143	1.867	53.56%
RakutenAI-3.0	267	137	1.949	51.31%
diffusiongemma-26B-A4B-it	267	145	1.841	54.31%
gemma-4-31B-it	267	145	1.841	54.31%

文章2

诶，真心说，香蕉是不是超好吃啊？哈哈
怎么说呢，那种绵密又粉糯的独特口感，简直让人受不了
而且放上几天开始发黑的时候，那股甜味，简直没法挡！
配牛奶一起吃，真的绝了，太好吃了！

モデル名（クリックで可視化）	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	88	58	1.517	65.91%
DeepSeek-V4-Pro	88	58	1.517	65.91%
LFM2.5-8B-A1B	88	80	1.1	90.91%
Llama-3-ELYZA-JP-8B	88	81	1.086	92.05%
Mistral-Medium-3.5-128B	88	84	1.048	95.45%
Qwen2.5-72B-Instruct	88	62	1.419	70.45%
Qwen3.6-27B	88	57	1.544	64.77%
RakutenAI-3.0	88	58	1.517	65.91%
diffusiongemma-26B-A4B-it	88	66	1.333	75.00%
gemma-4-31B-it	88	66	1.333	75.00%

文章3

现在开始就我国在东京湾发现的巨大不明生物（通称“哥斯拉”）的处置问题召开内阁会议。
接下来，请讨论针对哥斯拉应采取何种应对方式。
备选项为静观、清除、捕获，请从中作出选择。
无论作何选择，防卫省都将充分协商，并确保能够执行各项作战行动。

モデル名（クリックで可視化）	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	118	71	1.662	60.17%
DeepSeek-V4-Pro	118	71	1.662	60.17%
LFM2.5-8B-A1B	118	91	1.297	77.12%
Llama-3-ELYZA-JP-8B	118	101	1.168	85.59%
Mistral-Medium-3.5-128B	118	108	1.093	91.53%
Qwen2.5-72B-Instruct	118	73	1.616	61.86%
Qwen3.6-27B	118	73	1.616	61.86%
RakutenAI-3.0	118	71	1.662	60.17%
diffusiongemma-26B-A4B-it	118	81	1.457	68.64%
gemma-4-31B-it	118	81	1.457	68.64%

英語

文章1

This is a test text for measuring the compression efficiency of semantic information across different writing systems.
What we will look at are the character count and the token count. The character count is simply the number of characters, and the token count is measured using the Tokenizer provided by OpenAI.
Token counts may vary depending on the model, but for now we will use measurements on GPT5.x as provisional data.
For Japanese, the test executor is entering the text manually, whereas the English, Chinese, and Korean versions are AI translations. The translations are handled by Rakuten AI 3.0 released by Rakuten.
This is only meant to roughly visualize the semantic compression ratio and token efficiency, so please do not demand strict rigor.
That concludes the test text.

モデル名（クリックで可視化）	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	789	151	5.225	19.14%
DeepSeek-V4-Pro	789	151	5.225	19.14%

モデル名 (クリックで可視化)	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
LFM2.5-8B-A1B	789	153	5.157	19.39%
Llama-3-ELYZA-JP-8B	789	154	5.123	19.52%
Mistral-Medium-3.5-128B	789	153	5.157	19.39%
Qwen2.5-72B-Instruct	789	153	5.157	19.39%
Qwen3.6-27B	789	158	4.994	20.03%
RakutenAI-3.0	789	151	5.225	19.14%
diffusiongemma-26B-A4B-it	789	157	5.025	19.90%
gemma-4-31B-it	789	157	5.025	19.90%

文章2

Like, seriously, bananas are sooo good, right? lol
I mean, there's just something irresistible about that soft, kinda dense texture.
And when you leave them for a few days and they start getting brown, man, that
sweetness is just unbeatable!
Having them with milk makes them taste absolutely amazing!

モデル名 (クリックで可視化)	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	306	67	4.567	21.90%
DeepSeek-V4-Pro	306	67	4.567	21.90%
LFM2.5-8B-A1B	306	72	4.25	23.53%
Llama-3-ELYZA-JP-8B	306	67	4.567	21.90%
Mistral-Medium-3.5-128B	306	73	4.192	23.86%
Qwen2.5-72B-Instruct	306	66	4.636	21.57%
Qwen3.6-27B	306	66	4.636	21.57%
RakutenAI-3.0	306	67	4.567	21.90%
diffusiongemma-26B-A4B-it	306	68	4.5	22.22%
gemma-4-31B-it	306	68	4.5	22.22%

文章3

We will now begin the cabinet meeting regarding how to address the giant
unidentified creature discovered in Tokyo Bay in our country, commonly known as
Godzilla.

Accordingly, we must determine what kind of approach should be taken toward Godzilla.

The available options are to observe the situation, exterminate it, or capture it. Whichever option is chosen, the Ministry of Defense will conduct sufficient deliberations and ensure that all operational actions can be carried out.

モデル名 (クリックで可視化)	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	481	87	5.529	18.09%
DeepSeek-V4-Pro	481	87	5.529	18.09%
LFM2.5-8B-A1B	481	93	5.172	19.33%
Llama-3-ELYZA-JP-8B	481	88	5.466	18.30%
Mistral-Medium-3.5-128B	481	88	5.466	18.30%
Qwen2.5-72B-Instruct	481	87	5.529	18.09%
Qwen3.6-27B	481	90	5.344	18.71%
RakutenAI-3.0	481	87	5.529	18.09%
diffusiongemma-26B-A4B-it	481	88	5.466	18.30%
gemma-4-31B-it	481	88	5.466	18.30%

韓国語

文章1

이는 문자 종류별로 의미 정보의 압축 효율을 측정하기 위한 테스트용 텍스트입니다. 우리가 볼 지표는 글자 수와 토큰 수입니다. 글자 수는 그대로 세고, 토큰 수는 OpenAI가 제공하는 Tokenizer로 측정합니다. 토큰 수는 모델에 따라 차이가 있을 수 있지만, 우선은 GPT5.x에서의 토큰 수 측정을 임시 데 이터로 삼겠습니다. 일본어는 테스트 실행자가 직접 입력하며, 영어·중국어·한국어는 AI 번역본입니다. 번역은 라 쿠텐이 출시한 Rakuten AI 3.0이 담당합니다. 이는 어디까지나 의미 정보의 압축률과 토큰 효율을 대략적으로 가시화하려는 것이므로, 엄밀함 을 요구하지 말아 주세요. 이것으로 테스트용 문장을 마칩니다.

モデル名 (クリックで可視化)	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	353	215	1.642	60.91%
DeepSeek-V4-Pro	353	215	1.642	60.91%
LFM2.5-8B-A1B	353	192	1.839	54.39%
Llama-3-ELYZA-JP-8B	353	210	1.681	59.49%

モデル名（クリックで可視化）	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
Mistral-Medium-3.5-128B	353	188	1.878	53.26%
Qwen2.5-72B-Instruct	353	239	1.477	67.71%
Qwen3.6-27B	353	192	1.839	54.39%
RakutenAI-3.0	353	215	1.642	60.91%
diffusiongemma-26B-A4B-it	353	184	1.918	52.12%
gemma-4-31B-it	353	184	1.918	52.12%

文章2

아니 진짜, 바나나 완전 맛있지 않냐? ㅋㅋ
뭐랄까, 그 살짝 펍펍하면서도 특유의 식감이 진짜 못 참겠어.
그리고 며칠 놔뒀다가 까맣게 변해가기 시작할 때 그 달콤함은 진짜 끝내주지!
우유랑 같이 먹으면 진짜 최고로 맛있어!

モデル名（クリックで可視化）	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	131	110	1.191	83.97%
DeepSeek-V4-Pro	131	110	1.191	83.97%
LFM2.5-8B-A1B	131	98	1.337	74.81%
Llama-3-ELYZA-JP-8B	131	96	1.365	73.28%
Mistral-Medium-3.5-128B	131	95	1.379	72.52%
Qwen2.5-72B-Instruct	131	105	1.248	80.15%
Qwen3.6-27B	131	83	1.578	63.36%
RakutenAI-3.0	131	110	1.191	83.97%
diffusiongemma-26B-A4B-it	131	83	1.578	63.36%
gemma-4-31B-it	131	83	1.578	63.36%

文章3

우리나라 도쿄만에서 발견된 거대 정체불명 생물, 일명 고질라에 대한 대응 방안을 논의하는 각 의(국무회의)를 지금부터 시작하겠습니다.
이에 따라 고질라에 대해 어떠한 접근 방식을 취할 것인지 결정해야 합니다.
선택지는 상황을 지켜보는 것, 구제하는 것, 포획하는 것 가운데 하나입니다.
어떠한 선택지를 택하더라도 방위성에서 충분히 협의하여 모든 작전 행동을 실행할 수 있도록 하겠습니다.

モデル名 (クリックで可視化)	文字数	トークン数	文字数目安 (有効桁4)	トークン消費 [%]
DeepSeek-V3-Base	215	139	1.547	64.65%
DeepSeek-V4-Pro	215	139	1.547	64.65%
LFM2.5-8B-A1B	215	118	1.822	54.88%
Llama-3-ELYZA-JP-8B	215	127	1.693	59.07%
Mistral-Medium-3.5-128B	215	107	2.009	49.77%
Qwen2.5-72B-Instruct	215	129	1.667	60.00%
Qwen3.6-27B	215	110	1.955	51.16%
RakutenAI-3.0	215	139	1.547	64.65%
diffusiongemma-26B-A4B-it	215	118	1.822	54.88%
gemma-4-31B-it	215	118	1.822	54.88%